

对话系统的简介



```
graph TD; A[对话系统的简介] --> B[对话组件与流程]; B --> C[数据与深度学习]; C --> D[对话不足与未来];
```

对话组件与流程

数据与深度学习

对话不足与未来

# 什么是对话系统

- 对话系统是一个：人机交互界面
- 用更时髦的说法是：Conversational UI
- 通过文字、语音等自然语言交流方式，完成人机交互

# 对话系统的场景

1. 1、受限场景
2. 2、对话比其他人机交互方法成本低或效率高
  1. 学习成本低
  2. 认知成本低
  3. 任务效率高

# 对话系统的分类

- 从需要达到的目的来分类, 对话系统至少包括:
- 任务型 — 完成任务
- 问答型 — 回答问题
- 闲聊型 — 制造快乐

# 对话系统的目标

- 从成功标准来看：
- 任务型 — 快速解决问题
- 问答型 — 问题回答准确
- 闲聊型 — 聊！一直聊！

# 多轮对话？

- 多轮对话是一个伪命题，任何形式系统都期望是多轮的

对话系统的简介



对话组件与流程




数据与深度学习



对话不足与未来

# 对话系统结构



A Survey on Dialogue Systems: Recent Advances and New Frontiers  
[Chen et al., 2014]



# PIPELINE的目的

- 1、顺序工作符合人类思考逻辑
- 2、各个子模块解决不同任务, 分工协作
- 3、各个模块的输入和输出可以独立修改规则

# 任务型对话系统实现 — FRAME(帧)

- In general, a frame is a data structure potentially containing a name, a reference to a prototype frame, and a set of slots.
- GUS, A Frame-Driven Dialog System
- [Bobrow et al., 1977]

# 填满帧 = 任务完成

一个UNIT中的火车票购票样例

- 1、所有必要内容填满代表任务完成(至少是必要条件)
- 2、所有其他部分都是为了填满帧,所有系统动作都是为了帮助用户填满帧

对话意图名: BOOK\_TICKET

别名: 订票

添加词槽

词槽名	词槽别名	澄清话术
user_time	出发时间	什么时间出发?
user_from	出发站点	从哪出发?
user_to	到达站点	要到哪?
trainnumber	车次	要哪个车次的?

<https://ai.baidu.com/forum/topic/show/869808>

# 对话系统结构 — PIPELINE — 伪代码

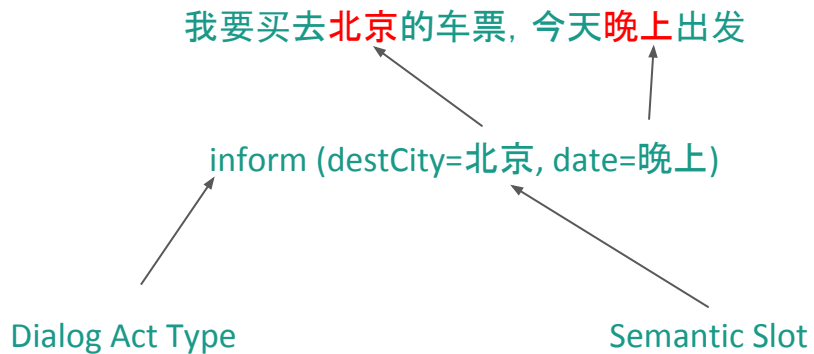
- 假设我们用伪代码(Python伪代码)的方式描述对话系统流程
- 假设所有的模块, 包括机器人本身都是函数
- 用户输入的对话字符串是utterance, 那么整个机器人函数看上去会是这样:

```
def bot(utterance):  
    x = utterance  
    x = nlu(x)  
    x = dst(x)  
    x = dpl(x)  
    x = nlg(x)  
    return x
```

幸运的是, 事实上还真是这样

# NLU的目标

- 自然语言理解目标: 拆解一句话的完整意义



# NLU的接口

- 输入:用户说的一句话
- 输出:针对这一句话的语义分析结果, 称之为用户行为

```
class NaturalLanguageUnderstanding(object):  
    def forward(self, utterance: str) -> UserAction:  
        user_action = UserAction()  
        # 处理逻辑  
        return user_action
```

# DST的目标

- 对话状态追踪:根据上下文, 改变当前的对话状态
- 这里的状态包括每一轮:用户说了什么, 系统做了什么, 系统的状态记忆

# DST的接口

输入: 用户行为, 状态历史

输出: 新的对话状态

```
class DialogStateTracker(object):  
    def forward(self,  
                init_state: DialogState,  
                history: List[DialogState],  
                user_action: UserAction  
                ) -> DialogState:  
        new_ds = DialogState()  
        # 处理逻辑  
        return new_ds
```



# DPL的目标

- 对话策略学习: 基于给定的对话状态(和历史), 作出给出下一步系统的行为

# DPL的接口

输入:对话状态与历史

输出:系统行为

```
class DialogPolicy(object):  
    def forward(self,  
                history: List[DialogState]  
    ) -> SystemAction:  
        system_action = SystemAction()  
        # 处理过程  
        return system_action
```

# NLG的目标

- 自然语言生成:根据系统行为,生成用户可以理解的自然语言
- 目标:
- 含义准确:应该准确表达出机器人想表达的含义
- 信息充足:在不影响阅读的情况下,把充足的信息提供给用户
- 讲话流利:语言流畅,不影响阅读
- 高可读性:当阐述多条信息时,应该有良好的组织性
- 并不无聊:最好能根据用户情绪、信息内容本身等有一定变化

# NLG的接口

输入:系统行为

输出:系统给用户的回复

```
class NLG(object):  
    def forward(self,  
                system_action: SystemAction) -> str:  
        system_response = SystemResponse()  
        return system_response
```

对话系统的简介



对话组件与流程

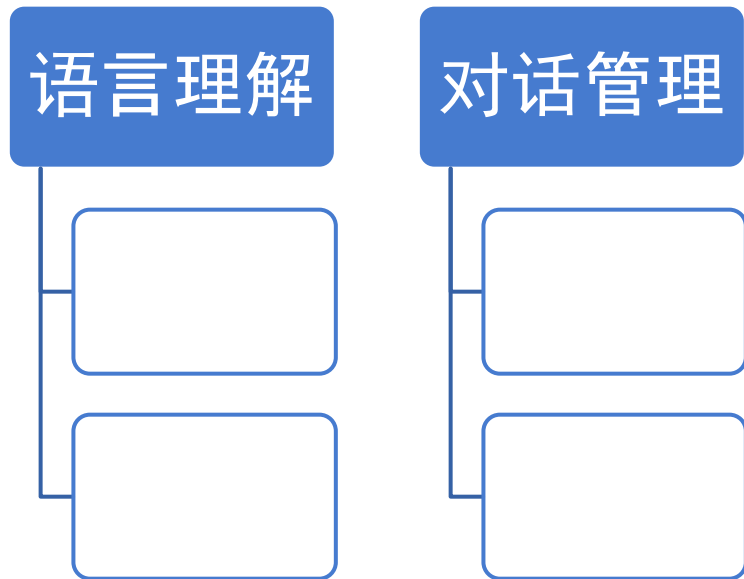


数据与深度学习



对话不足与未来

# 不同组件的深度学习构建



# NLU数据

语句：我要买去 北京 的车票，今天 晚上 出发

领域： travel

意图： inform

实体： ⓘ 目的地：北京 × ⓘ 日期时间：晚上 ×

# NLU模型 — 意图、领域识别

- Input: 我要买去北京的车票, 今天晚上出发
- Output Intent: inform
- Output Domain: travel

Intent Detection = 短文本分类任务



# NLU INTENT KERAS — 一个简易的文本分类器

```
def make_model(n_size, n_output, n_embedding, n_vocab):  
    model = Sequential()  
    model.add(Embedding(n_vocab, n_embedding, mask_zero=True))  
    model.add(LSTM(n_size))  
    model.add(Dense(n_output))  
    model.add(Activation('softmax'))  
    model.compile(loss='categorical_crossentropy',  
                  optimizer='adam',  
                  metrics=['accuracy'])  
    return model
```

# NLU模型 — 实体识别(语义槽识别)

- 序列标注：
- Input：我要买去北京的车票，今天晚上出发
- Output：O O O O O Bc Ic O O O O O O Bd Id O O

- Bc = Beginning-City, Ic = Inside-City
- Bd = Beginning-Date, Id = Inside-Date
- O = Outside

IOB: [https://en.wikipedia.org/wiki/Inside%E2%80%93outside%E2%80%93beginning\\_\(tagging\)](https://en.wikipedia.org/wiki/Inside%E2%80%93outside%E2%80%93beginning_(tagging))

# NLU NER KERAS — 一个简易的NER实现

```
def make_model(n_size, n_output, n_embedding, n_vocab):  
    """一个简单的NER实现，没有CRF层"""  
    model = Sequential()  
    model.add(Embedding(n_vocab, n_embedding, mask_zero=True))  
    model.add(Bidirectional(LSTM(n_size, return_sequences=True)))  
    model.add(Bidirectional(LSTM(n_size, return_sequences=True)))  
    model.add(TimeDistributed(Dense(n_output)))  
    model.add(Activation('softmax'))  
    model.compile(optimizer='adam', loss='categorical_crossentropy')  
    return model
```

# 对话数据

对话数据本质上我们可以认为是一段故事，或者剧本

右边的剧本来自于Rasa, 一家使用机器学习完成对话机器人构建的公司

[https://raw.githubusercontent.com/RasaHQ/rasa\\_core/master/examples/restaurantbot/data/stories.md](https://raw.githubusercontent.com/RasaHQ/rasa_core/master/examples/restaurantbot/data/stories.md)

## story_00914561	
* greet	用户:你好
- utter_ask_howcanhelp	系统:我能帮你做什么呢？
* inform{"cuisine": "italian"}	用户:我要预订一家意大利餐厅
- utter_on_it	系统:我在听
- utter_ask_location	系统:你要找哪里的
* inform{"location": "paris"}	用户:巴黎
- utter_ask_numpeople	系统:要几个人
* inform{"people": "six"}	用户:6个人
- utter_ask_price	系统:要什么价位的
* inform{"price": "cheap"}	用户:便宜的
- utter_ask_moreupdates	系统:如果你要修改什么请告诉我
* inform{"people": "two"}	用户:换成两个人吧
- utter_ask_moreupdates	系统:如果你要修改什么请告诉我
* inform{"location": "madrid"}	用户:马德里的餐厅
- utter_ask_moreupdates	系统:如果你要修改什么请告诉我
* inform{"cuisine": "spanish"}	用户:还是西班牙菜吧
- utter_ask_moreupdates	系统:如果你要修改什么请告诉我
* deny	用户:就这样不换了
- utter_ack_dosearch	系统:好的我开始搜索了
- action_search_restaurants	(后台的搜索功能)
- action_suggest	(后台的推荐功能)

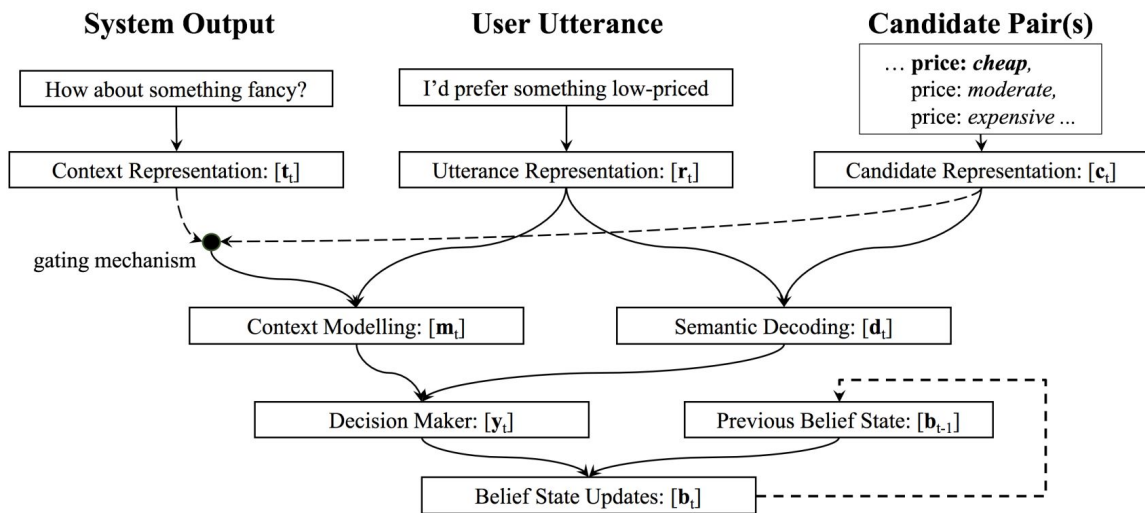
# 对话模型 — 定义

- In slot-based spoken Dialogue systems, tracking the entities in context can be cast as **slot carryover task** only the relevant slots from the dialogue context are carried over to the current turn.

Improving Long Distance Slot Carryover in Spoken Dialogue Systems

[Chen et al., 2019]

# 对话模型 — 对话状态更新 — 复杂版



Fully Statistical Neural Belief Tracking  
[Mrkšić et al., 2018]

# DST KERAS

```
def make_model(n_size, n_output):  
    model = Sequential()  
    model.add(LSTM(n_size))  
    model.add(Dense(n_output))  
    model.add(Activation('sigmoid'))  
    model.compile(loss='binary_crossentropy',  
                  optimizer='adam',  
                  metrics=['accuracy'])  
  
    return model
```

# 对话模型 — 对话状态策略学习 — 机器学习

- 将对话上下文建模
- 给出系统行为概率分布



# DPL KERAS

```
def make_model(n_size, n_output):  
    model = Sequential()  
    model.add(LSTM(n_size))  
    model.add(Dense(n_output))  
    model.add(Activation('softmax'))  
    model.compile(loss='categorical_crossentropy',  
                  optimizer='adam',  
                  metrics=['accuracy'])  
  
    return model
```

# NLG模型 — 大部分时候简单就好

- `def hello(user_name=None):`
- `If user_name is not None:`
- `return f'你好, {user_name}'`
- `return '你好'`

# NLG模型 — 更好

- 1、基于用户情绪或用户画像的专家系统
- 2、在拥有更多对话生成数据的情况下，提供基于 Sequence-to-sequence 的NLG模型。参考文章 A Context-aware Natural Language Generator for Dialogue Systems [Dušek et al., 2016]

对话系统的简介



对话组件与流程



数据与深度学习



对话不足与未来

# 强化学习 — 模型的未来？

- 1、如何进行User Simulation
- 2、如何和规则模型互动
- 3、如何个解决训练数据问题

# 不足

- 1、系统脆弱: 对话流程如果脱离设计的时候, 容易出现偏差
- 2、工具欠缺: 依然还是缺乏足够方便的工具, 即便我们有LUIS、UNIT、RASA
- 3、规范欠缺: 没有一个主流设计思想引导, 缺乏系统性
- 4、数据成本: 数据收集成本高, 对话很难扩展

# 未来

- 1、以产品设计思想为引导, 先进工具为前提
  - 在足够的系统规范下, 以各种方便的可演进的工具为前提
- 2、设计在有限制的情况下更高效的对话
  - 对机器人充分理解的设计下, 利用“游戏规则”, 把握用户预期
- 3、与其他自然语言产品的融合
  - 游戏、搜索、APP, 互补与借鉴

# 我们还有很多没说

- 1、数据挖掘与扩展
- 2、产品如何设计
- 3、问答系统在哪
- 4、如何组合一切



# 演示

```
user:你好
user_action {'text': '你好', 'tokens': ['你', '好'], 'intent': 'hello', 'domain': '', 'slots': [], 'ner_slot_filler': {'slots': []}}
pred [0. 0. 0. 0. 0. 0. 0. 0.]
new state after fill -----
user_domain: None
user_intent: None
slots:
informable      城市      None
informable      时间      None
informable      任务      None
informable      数字      None
requestable     城市      None
requestable     时间      None
requestable     任务      None
requestable     数字      None
sys_intent: None
-----
new system_action hello
sys: 你好啊，我是帕蒂安
user:
```

# THANKS

- 所有文中代码: <https://github.com/deepdialog/deepdialog>
- 2019/10